

Інструкція до практичної роботи №31

Тема: Система розпізнавання тексту FineReader, онлайн-сервіси. Перевірка граматики і правопису

Мета роботи

- Ознайомитися з поняттям оптичного розпізнавання символів (OCR)
- Вивчити можливості програми ABBYY FineReader та онлайн-сервісів OCR
- Навчитися розпізнавати текст зі сканованих зображень
- Освоїти перевірку орфографії та граматики розпізнаного тексту
- Порівняти точність розпізнавання для різних типів вихідних матеріалів

Теоретичні відомості

1. Поняття оптичного розпізнавання символів (OCR)

OCR (Optical Character Recognition) — технологія перетворення зображення друкованого чи рукописного тексту (скан, фотографія) в редагований текстовий формат шляхом аналізу форм символів та їх зіставлення з еталонними шаблонами або за допомогою нейронних мереж.

2. Програма ABBYY FineReader

ABBYY FineReader — одна з провідних програм розпізнавання тексту, що підтримує понад 190 мов, розпізнавання складних макетів (таблиці, колонки, зображення) та збереження результату в численних форматах: DOCX, PDF, XLSX, TXT.

3. Онлайн-сервіси OCR

Сервіс	Особливості
Google Drive OCR	вбудована функція розпізнавання при відкритті зображення як Google Документа
OnlineOCR.net	безкоштовний сервіс з обмеженням кількості сторінок на добу
i2OCR	підтримка багатьох мов, включно з українською

4. Фактори, що впливають на точність розпізнавання

- Якість вихідного зображення (роздільна здатність, чіткість, відсутність шумів)

- Тип шрифту (друкований розпізнається значно точніше за рукописний)
- Правильність визначеної мови розпізнавання
- Складність макета сторінки (таблиці, колонки, змішаний текст із зображеннями)

5. Перевірка граматики та правопису

Засіб	Опис
Вбудована перевірка Microsoft Word	підкреслює орфографічні й граматичні помилки під час набору
LanguageTool	онлайн-сервіс перевірки граматики й стилю для багатьох мов, включно з українською
Grammarly	популярний сервіс перевірки англomовних текстів з розширеними стилістичними порадами

6. Особливості перевірки українського тексту

Перевірка українськомовних текстів потребує відповідних мовних словників та коректно встановленої мови перевірки в застосунку — застарілі або неповні словники можуть некоректно позначати правильні слова як помилки, особливо власні назви чи неологізми.

7. Постобробка розпізнаного тексту

Навіть за високої точності OCR розпізнаний текст зазвичай потребує постобробки: виправлення помилок розпізнавання (плутанина схожих символів, наприклад «0» та «О»), відновлення форматування абзаців та перевірки правильності розстановки розділових знаків.

Обладнання та програмне забезпечення

- Персональний комп'ютер з доступом до інтернету
- Програма ABBYY FineReader (або пробна версія)
- Скановане зображення друкованого тексту для розпізнавання
- Доступ до онлайн-сервісів OCR та перевірки граматики

Хід роботи

Завдання 1. Встановлення та запуск FineReader (10 хв)

Крок 1. Встановіть (або запустіть наявну) пробну версію ABBYY FineReader.

Крок 2. Ознайомтеся з інтерфейсом програми: панель інструментів, область попереднього перегляду, область розпізнаного тексту.

Крок 3. Перегляньте підтримувані мови розпізнавання та переконайтеся у наявності української мови.

Завдання 2. Розпізнавання тексту зі сканованого зображення у FineReader (20 хв)

Крок 1. Відкрийте у FineReader підготовлене скановане зображення (або сфотографований текст).

Крок 2. Оберіть мову розпізнавання (українська/англійська відповідно до тексту).

Крок 3. Запустіть процес розпізнавання та дочекайтеся результату.

Крок 4. Перегляньте отриманий текст та порівняйте його з оригінальним зображенням, звертаючи увагу на розбіжності.

Завдання 3. Порівняння результату з онлайн-сервісом OCR (15 хв)

Крок 1. Завантажте те саме зображення в один з онлайн-сервісів OCR (наприклад, i2OCR).

Крок 2. Оберіть відповідну мову розпізнавання та запустіть обробку.

Крок 3. Порівняйте отриманий результат з розпізнаванням у FineReader за кількістю помилок.

Крок 4. Занесіть порівняння до звіту.

Завдання 4. Перевірка орфографії розпізнаного тексту вбудованими засобами Word (10 хв)

Крок 1. Скопіюйте розпізнаний текст у документ Microsoft Word.

Крок 2. Перевірте, чи коректно визначена мова перевірки (українська).

Крок 3. Перегляньте позначені орфографічні помилки та виправте їх за допомогою контекстного меню.

Завдання 5. Перевірка граматики онлайн-сервісом (15 хв)

Крок 1. Відкрийте сервіс LanguageTool (languagetool.org).

Крок 2. Вставте розпізнаний та відредагований текст у поле перевірки.

Крок 3. Оберіть відповідну мову перевірки.

Крок 4. Перегляньте знайдені граматичні та стилістичні зауваження, застосуйте доречні виправлення.

Завдання 6. Порівняння точності розпізнавання для різних типів тексту (10 хв)

Крок 1. Підготуйте (за наявності) зразок рукописного тексту.

Крок 2. Виконайте його розпізнавання у FineReader або відповідному сервісі.

Крок 3. Порівняйте відсоток правильно розпізнаних символів для друкованого та рукописного тексту.

Крок 4. Зробіть висновок про обмеження сучасних систем OCR для рукописного тексту.

Практичні завдання для самостійного виконання

Завдання А (базовий рівень)

1. Опишіть принцип роботи технології OCR
2. Складіть перелік факторів, що впливають на точність розпізнавання
3. Поясніть різницю між перевіркою орфографії та перевіркою граматики

Завдання Б (середній рівень)

1. Порівняйте точність розпізнавання тексту різними шрифтами (звичайний, курсив, декоративний)
2. Дослідіть можливості пакетного розпізнавання кількох сторінок одночасно у FineReader
3. Порівняйте якість перевірки українського тексту сервісом LanguageTool та вбудованою перевіркою Word

Завдання В (високий рівень)

1. Дослідіть використання нейромережевих технологій у сучасних системах OCR (порівняно з класичними алгоритмами)
2. Підготуйте порівняльний аналіз трьох онлайн-сервісів OCR за точністю розпізнавання українського тексту
3. Розробіть чек-лист постобробки розпізнаного тексту для мінімізації помилок

Контрольні питання

1. Що таке технологія OCR?
2. Які можливості має програма ABBYY FineReader?
3. Назвіть приклади онлайн-сервісів OCR.
4. Які фактори впливають на точність розпізнавання тексту?
5. Чому рукописний текст розпізнається гірше за друкований?
6. Якими засобами можна перевірити орфографію тексту?
7. Чим перевірка граматики відрізняється від перевірки орфографії?
8. Які особливості перевірки українськомовного тексту?

9. Що таке постобробка розпізнаного тексту?
10. Які типові помилки виникають при розпізнаванні символів?
11. У які формати можна зберегти результат розпізнавання у FineReader?
12. Чому важливо правильно вказувати мову розпізнавання перед обробкою?

Форма звіту

1. Мета роботи
2. Опис інтерфейсу та можливостей FineReader
3. Результат розпізнавання тексту у FineReader
4. Результат розпізнавання онлайн-сервісом OCR та порівняння
5. Результати перевірки орфографії у Word
6. Результати перевірки граматики через LanguageTool
7. Порівняння точності розпізнавання друкованого та рукописного тексту
8. Виконане самостійне завдання (на вибір А, Б або В)
9. Відповіді на контрольні питання (мінімум 8)
10. Висновки

Критерії оцінювання

Шкала оцінювання (12-бальна система):

- 12 балів — виконані всі завдання з повною документацією, коректно розпізнано та перевірено текст усіма засобами, виконане завдання високого рівня (В), вичерпні відповіді на всі контрольні питання
- 10-11 балів — виконані всі основні завдання, якісна документація, виконане завдання середнього рівня (Б)
- 7-9 балів — виконані обов'язкові завдання, достатня документація, виконане базове завдання (А)
- 4-6 балів — виконана більша частина завдань, поверхневе розуміння теми
- 1-3 бали — виконана менша частина завдань, недостатня документація
- 0 балів — робота не виконана

Література та ресурси

1. Документація Abbyy FineReader: <https://www.abbyy.com/finereader>

2. Сервіс перевірки граматики LanguageTool: <https://languagetool.org>
3. Матеріали щодо технологій оптичного розпізнавання символів
4. "Інформаційні технології опрацювання тексту" — навчальний посібник

Додаток А. Глосарій термінів

- **OCR** — оптичне розпізнавання символів — технологія перетворення зображення тексту в редагований формат
- **ABBYY FineReader** — програмний продукт для розпізнавання тексту та роботи з документами
- **LanguageTool** — онлайн-сервіс перевірки граматики та стилю тексту
- **Постобробка** — виправлення помилок і форматування після автоматичного розпізнавання тексту
- **Макет сторінки** — структура розташування тексту, таблиць і зображень на сторінці
- **Мовний словник** — база даних слів мови, що використовується для перевірки орфографії
- **Рукописний текст** — текст, написаний від руки, складніший для розпізнавання порівняно з друкованим

Підсумки практичної роботи

Після виконання цієї практичної роботи ви:

Дізналися:

- Принципи роботи технології оптичного розпізнавання символів
- Можливості FineReader та онлайн-сервісів OCR
- Способи перевірки орфографії та граматики тексту

Навчилися:

- Розпізнавати текст зі сканованих зображень у FineReader та онлайн-сервісах
- Перевіряти орфографію та граматику розпізнаного тексту
- Оцінювати та порівнювати точність розпізнавання різних систем OCR

Викладач: _____

Дата: _____