

Інструкція до практичної роботи №32

Тема: Сканування, розпізнавання та редагування тексту в FineReader та онлайн-сервісах. Перетворення PDF зображень у Word

Мета роботи

- Закріпити навички сканування багатосторінкових документів
- Навчитися редагувати макет розпізнаного документа у FineReader
- Освоїти збереження розпізнаного тексту в різних форматах
- Навчитися перетворювати PDF-зображення на редагований документ Word
- Порівняти якість конвертації засобами FineReader та онлайн-сервісів

Теоретичні відомості

1. Сканування багатосторінкового документа

Для розпізнавання багатосторінкових документів (книг, звітів) зручно використовувати сканери з автоподавачем або послідовне сканування кожної сторінки з подальшим об'єднанням у FineReader в один проєкт — це дозволяє обробити весь документ і зберегти результат як єдиний файл.

2. Редагування макета в FineReader

Після розпізнавання FineReader надає можливість редагувати макет сторінки: коригувати межі текстових блоків, виправляти неправильно розпізнані таблиці, видаляти зайві елементи (плями, лінії сканування) — це підвищує точність кінцевого результату перед експортом.

3. Формати збереження результату

Формат	Призначення
DOCX	повністю редагований документ Word зі збереженим форматуванням
PDF (текстовий шар)	зображення оригіналу з прихованим текстовим шаром для пошуку й копіювання
TXT	простий текст без форматування
XLSX	збереження розпізнаних таблиць у форматі Excel

4. Перетворення сканованого PDF у редагований Word

PDF-файл, що є фактично зображенням (наприклад, скан книги без текстового шару), не можна редагувати чи копіювати з нього текст напряму.

Для перетворення такого PDF у редагований документ Word необхідне застосування OCR — або через FineReader, або через спеціалізовані онлайн-конвертери.

5. Онлайн-конвертери PDF у Word

- **Smallpdf** — популярний сервіс конвертації PDF з підтримкою OCR для сканованих документів
- **ILovePDF** — набір інструментів для роботи з PDF, включно з конвертацією у Word
- **Adobe Acrobat Online** — офіційний сервіс Adobe для конвертації PDF

6. Збереження форматування при конвертації

Якісна конвертація повинна максимально зберігати оригінальне форматування: розташування абзаців, таблиці, вбудовані зображення. Складні макети (багатосторінкові тексти, елементи дизайну) частіше призводять до втрати або спотворення форматування при автоматичній конвертації.

7. Типові помилки розпізнавання та їх виправлення

- Плутанина схожих символів (O/0, l/1/I) — потребує уважної вичитки
- Неправильне розпізнавання таблиць — можлива потреба ручного відновлення структури
- Втрата абзаців або їх злиття — виправляється вручну після експорту
- Помилки в спеціальних символах і формулах — часто потребують ручного введення

Обладнання та програмне забезпечення

- Персональний комп'ютер з доступом до інтернету
- Програма ABBYY FineReader
- Багатосторінковий документ або сканер/камера для його створення
- PDF-файл, що містить скановане (нередаговане) зображення тексту

Хід роботи

Завдання 1. Сканування багатосторінкового документа (10 хв)

Крок 1. Підготуйте (відскануйте або сфотографуйте) 2-3 сторінки тестового документа.

Крок 2. Збережіть отримані зображення в одну папку у форматі JPEG або PNG.

Крок 3. Перевірте якість зображень (чіткість, відсутність перекосів) перед подальшою обробкою.

Завдання 2. Розпізнавання та редагування макета у FineReader (20 хв)

Крок 1. Створіть новий проєкт у FineReader та додайте всі підготовлені сторінки.

Крок 2. Запустіть розпізнавання всього документа.

Крок 3. Перегляньте розпізнаний макет кожної сторінки та виправте виявлені неточності (межі блоків тексту, таблиці).

Крок 4. Видаліть зайві елементи (плями, лінії сканування) за наявності.

Завдання 3. Збереження розпізнаного документа у форматі Word (10 хв)

Крок 1. Оберіть у FineReader експорт у формат Microsoft Word (DOCX).

Крок 2. Налаштуйте параметри збереження форматування (точне збереження макета або лише текст).

Крок 3. Збережіть отриманий файл та відкрийте його для перевірки.

Завдання 4. Конвертація PDF-зображення у Word онлайн-сервісом (15 хв)

Крок 1. Відкрийте обраний онлайн-конвертер (Smallpdf або ILovePDF).

Крок 2. Завантажте підготовлений сканований PDF-файл.

Крок 3. Оберіть функцію «PDF to Word» з увімкненим розпізнаванням тексту (OCR), якщо доступно.

Крок 4. Завантажте отриманий результат конвертації.

Завдання 5. Порівняння якості конвертації FineReader vs онлайн-сервіс (10 хв)

Крок 1. Відкрийте обидва отримані документи Word поруч.

Крок 2. Порівняйте точність розпізнаного тексту, збереження форматування та структури таблиць.

Крок 3. Занесіть результати порівняння до таблиці.

Критерій	FineReader	Онлайн-сервіс
Точність тексту		

Критерій	FineReader	Онлайн-сервіс
Збереження форматування		
Розпізнавання таблиць		

Завдання 6. Виправлення помилок розпізнавання в отриманому документі (15 хв)

Крок 1. Уважно перегляньте отриманий документ Word та знайдіть помилки розпізнавання.

Крок 2. Виправте плутанину схожих символів, відновіть правильну структуру абзаців.

Крок 3. За потреби відновіть структуру таблиць, якщо вона була спотворена.

Крок 4. Виконайте фінальну перевірку орфографії засобами Word.

Практичні завдання для самостійного виконання

Завдання А (базовий рівень)

1. Опишіть етапи роботи з багатосторінковим документом у FineReader
2. Складіть перелік форматів, у яких можна зберегти результат розпізнавання
3. Поясніть, чому скановане зображення PDF не можна редагувати напряму

Завдання Б (середній рівень)

1. Порівняйте якість розпізнавання таблиць складної структури (об'єднані клітинки) у FineReader та онлайн-сервісі
2. Дослідіть функцію створення PDF з текстовим шаром (searchable PDF) у FineReader
3. Проаналізуйте типові помилки розпізнавання на прикладі документа з математичними формулами

Завдання В (високий рівень)

1. Дослідіть пакетну обробку декількох документів у FineReader (Hot Folder) для автоматизації розпізнавання
2. Підготуйте порівняльний аналіз трьох онлайн-конвертерів PDF у Word за якістю збереження форматування
3. Розробіть покрокову інструкцію оцифрування архіву паперових документів для навчального закладу

Контрольні питання

1. Як організувати сканування багатосторінкового документа?
2. Що дозволяє редагувати макет у FineReader?
3. У яких форматах можна зберегти результат розпізнавання?
4. Чим текстовий PDF відрізняється від сканованого зображення PDF?
5. Якими онлайн-сервісами можна конвертувати PDF у Word?
6. Що впливає на якість збереження форматування при конвертації?
7. Які типові помилки розпізнавання тексту трапляються найчастіше?
8. Як виправити неправильно розпізнану таблицю?
9. Що таке PDF з текстовим шаром (searchable PDF)?
10. Чому важливо перевіряти результат розпізнавання перед використанням документа?
11. Які переваги FineReader порівняно з онлайн-сервісами конвертації?
12. Що робити, якщо конвертація спотворила структуру документа?

Форма звіту

1. Мета роботи
2. Опис підготовленого багатосторінкового документа
3. Опис розпізнавання та редагування макета у FineReader
4. Збережений документ Word (опис результату)
5. Результати конвертації PDF у Word онлайн-сервісом
6. Таблиця порівняння якості конвертації
7. Опис виправлених помилок розпізнавання
8. Виконане самостійне завдання (на вибір А, Б або В)
9. Відповіді на контрольні питання (мінімум 8)
10. Висновки

Критерії оцінювання

Шкала оцінювання (12-бальна система):

- 12 балів — виконані всі завдання з повною документацією, якісно розпізнано та відредаговано документ, виконане завдання високого рівня (В), вичерпні відповіді на всі контрольні питання
- 10-11 балів — виконані всі основні завдання, якісна документація, виконане завдання середнього рівня (Б)
- 7-9 балів — виконані обов'язкові завдання, достатня документація, виконане базове завдання (А)

- 4-6 балів — виконана більша частина завдань, поверхнєве розуміння теми
- 1-3 бали — виконана менша частина завдань, недостатня документація
- 0 балів — робота не виконана

Література та ресурси

1. Документація ABBYY FineReader: <https://www.abbyy.com/finereader>
2. Сервіс Smallpdf: <https://smallpdf.com>
3. Сервіс ILovePDF: <https://www.ilovepdf.com>
4. "Інформаційні технології опрацювання тексту" — навчальний посібник

Додаток А. Глосарій термінів

- **Searchable PDF** — PDF-документ із прихованим текстовим шаром, придатним для пошуку й копіювання
- **Макет сторінки** — структура розташування текстових блоків, таблиць і зображень
- **Hot Folder** — функція автоматичної пакетної обробки файлів з визначеної папки
- **Конвертація** — перетворення документа з одного формату в інший
- **OCR-шар** — прихований текстовий шар, накладений на зображення відсканованої сторінки
- **Структура таблиці** — розташування рядків, стовпців і об'єднаних клітинок таблиці
- **Постредагування** — виправлення помилок після автоматичної обробки документа

Підсумки практичної роботи

Після виконання цієї практичної роботи ви:

Дізналися:

- Особливості роботи з багатосторінковими документами у FineReader
- Способи перетворення сканованого PDF у редагований Word
- Типові помилки розпізнавання та способи їх виправлення

Навчилися:

- Розпізнавати та редагувати макет багатосторінкового документа
- Конвертувати скановані PDF-файли у Word засобами FineReader та онлайн-сервісів
- Виправляти помилки розпізнавання в отриманому документі

Викладач: _____

Дата: _____