

Інструкція до практичної роботи №7

Тема: Конвертація та форматування складних PDF-документів у MS Word

Мета роботи

- Вивчити структуру формату PDF та особливості його конвертації в редаговані формати
- Освоїти способи конвертації PDF у Word вбудованими та онлайн-засобами
- Навчитися виправляти типові проблеми форматування після конвертації складних документів
- Ознайомитися з роботою OCR при конвертації сканованих PDF
- Розвинути навички відновлення структури документа (таблиці, колонки, зображення)

Теоретичні відомості

1. Формат PDF та його особливості

PDF (Portable Document Format) — формат файлів, розроблений Adobe, що зберігає точний вигляд документа незалежно від пристрою чи програмного забезпечення.

Типи PDF-документів за походженням:

- **Текстовий (нативний) PDF** — створений з текстового редактора чи іншої програми, містить справжній текстовий шар
- **Сканований (растровий) PDF** — набір зображень сторінок без текстового шару, отриманий скануванням паперового документа
- **Змішаний PDF** — поєднує текстові елементи із вставленими зображеннями/сканами

Складність конвертації PDF у Word зростає при наявності: багатоколонкового макета, вкладених таблиць, текстових полів у зображеннях, складного форматування (виноски, колонтитули), вбудованих шрифтів, що не підтримуються у Word.

2. Способи конвертації PDF у Word

Спосіб	Опис	Особливості
Відкриття PDF безпосередньо в Word	Word автоматично розпізнає та конвертує структуру	Працює для нескладних текстових PDF
Онлайн-конвертери (Smallpdf, ILovePDF)	Завантаження файлу на сервіс з подальшим завантаженням результату	Зручно, але потребує інтернету, обмеження на обсяг файлу

Спосіб	Опис	Особливості
Adobe Acrobat (Export PDF)	Професійний інструмент конвертації з високою точністю збереження макета	Платна підписка для повного функціоналу
OCR-програми (ABBY FineReader)	Розпізнавання сканованих PDF з відновленням макета	Необхідне для сканованих документів без текстового шару

3. Типові проблеми після конвертації та їх причини

Проблема	Причина
Розбитий на окремі текстові блоки текст	PDF зберігає текст як окремі позиційні елементи, а не суцільний потік
Втрачене форматування таблиць	Складна структура таблиці не завжди коректно розпізнається
Неправильні розриви рядків усередині абзаців	Кожен рядок PDF може інтерпретуватися як окремий абзац
Зміщені або накладені зображення	Абсолютне позиціонування об'єктів у PDF конфліктує з потоковою версткою Word
Нерозпізнаний текст (кракозябри або відсутність тексту)	Сканований PDF без текстового шару або нестандартне кодування шрифтів

4. Інструменти виправлення форматування у Word

Основні прийоми відновлення структури документа після конвертації:

- **Заміна розривів рядків на пробіли** — використання функції "Знайти і замінити" зі спеціальними символами (^p, ^l)
- **Очищення форматування** — інструмент "Очистити все форматування" перед повторним застосуванням стилів
- **Відображення непечатних символів** — Ctrl+Shift+8 (¶) для виявлення прихованих розривів та пробілів
- **Перебудова таблиць** — ручне об'єднання/розбиття комірок при некоректному розпізнаванні
- **Застосування стилів заголовків** — використання вбудованих стилів для відновлення ієрархії документа

5. Розпізнавання сканованих PDF (OCR)

Для сканованих документів без текстового шару застосовують програми з функцією OCR (наприклад, ABBYY FineReader, Adobe Acrobat Pro), які:

- Розпізнають текст на зображенні сторінки
- Визначають зони тексту, таблиць, зображень окремо
- Створюють редагований документ зі збереженням оригінального макета
- Дозволяють обрати мову розпізнавання для підвищення точності

Обладнання та програмне забезпечення

- Персональний комп'ютер з MS Word
- Набір тестових PDF-файлів: простий текстовий, багатостовпковий, з таблицями, сканований
- Доступ до інтернету для онлайн-конвертерів
- Adobe Acrobat Reader (безкоштовна версія)
- Програма ABBYY FineReader (за наявності) або аналогічний OCR-інструмент

Хід роботи

Завдання 1. Аналіз типів наданих PDF-документів (10 хв)

Крок 1. Відкрийте кожен з наданих тестових PDF-файлів в Adobe Acrobat Reader.

Крок 2. Спробуйте виділити та скопіювати текст у кожному файлі — визначте, чи є текстовий шар.

Крок 3. Занесіть результати до таблиці:

Файл	Тип (текстовий/сканований/змішаний)	Складність макета
Файл 1		
Файл 2		
Файл 3		

Завдання 2. Конвертація простого текстового PDF у Word (15 хв)

Крок 1. Відкрийте простий текстовий PDF-файл безпосередньо у MS Word (Файл → Відкрити → оберіть PDF).

Крок 2. Дочекайтесь автоматичної конвертації та огляньте результат.

Крок 3. Порівняйте макет отриманого документа з оригіналом PDF.

Крок 4. Збережіть результат як .docx.

Крок 5. Зробіть скріншот порівняння оригіналу та результату конвертації.

Завдання 3. Конвертація багатостовпкового документа (20 хв)

Крок 1. Конвертуйте PDF-файл зі складним багатостовпковим макетом (газетний стиль) у Word.

Крок 2. Проаналізуйте, як Word розподілив текст колонок — послідовно чи змішано.

Крок 3. За потреби виправте порядок тексту, використовуючи функцію колонок Word (Макет → Колонки).

Крок 4. Увімкніть відображення непечатних символів (Ctrl+Shift+8) для виявлення прихованих розривів.

Крок 5. Занесіть до таблиці виявлені проблеми та способи їх виправлення:

Проблема	Спосіб виправлення
1.	
2.	

Завдання 4. Відновлення таблиць після конвертації (20 хв)

Крок 1. Конвертуйте PDF-документ, що містить таблицю, у Word.

Крок 2. Порівняйте структуру отриманої таблиці з оригіналом (кількість рядків/стовпців, об'єднані комірки).

Крок 3. Виправте виявлені розбіжності: об'єднайте/розбийте комірки за потреби (Макет таблиці → Об'єднати/Розбити комірки).

Крок 4. Застосуйте табличний стиль оформлення для покращення вигляду.

Крок 5. Зробіть скріншот таблиці до та після виправлення.

Завдання 5. Розпізнавання сканованого PDF за допомогою OCR (25 хв)

Крок 1. Відкрийте сканований PDF-файл (без текстового шару) у програмі з підтримкою OCR (ABBYY FineReader або Adobe Acrobat Pro → Розпізнати текст).

Крок 2. Оберіть мову розпізнавання відповідно до мови документа.

Крок 3. Запустіть процес розпізнавання та дочекайтесь результату.

Крок 4. Експортуйте розпізнаний документ у формат .docx.

Крок 5. Відкрийте отриманий файл у Word та оцініть якість розпізнавання (наявність помилок у тексті).

Крок 6. Занесіть результати до таблиці:

Параметр	Значення
Програма розпізнавання	
Мова розпізнавання	
Кількість помилок на сторінку (приблизно)	

Завдання 6. Очищення та фінальне форматування документа (15 хв)

Крок 1. Оберіть один з конвертованих документів (Завдання 3-5) для фінального оформлення.

Крок 2. Виконайте очищення зайвого форматування (Головна → Очистити все форматування) для проблемних фрагментів.

Крок 3. Застосуйте вбудовані стилі заголовків до назв розділів документа.

Крок 4. Перевірте орфографію та виправте помилки розпізнавання за допомогою вбудованої перевірки правопису Word.

Крок 5. Збережіть фінальну версію документа.

Завдання 7. Порівняння онлайн-конвертерів (15 хв)

Крок 1. Завантажте один з тестових PDF-файлів на два різні онлайн-конвертери (наприклад, Smallpdf та ILovePDF).

Крок 2. Порівняйте отримані результати конвертації за якістю збереження форматування.

Крок 3. Занесіть результати до таблиці:

Сервіс	Якість збереження форматування	Обмеження (розмір/кількість файлів)
Сервіс 1		
Сервіс 2		

Крок 4. Сформулюйте висновок про доцільність використання онлайн-конвертерів для конфіденційних документів (питання приватності даних).

Практичні завдання для самостійного виконання

Завдання А (базовий рівень)

1. Опишіть відмінності між текстовим та сканованим PDF
2. Складіть перелік типових проблем форматування після конвертації PDF у Word
3. Поясніть призначення технології OCR при конвертації сканованих документів

Завдання Б (середній рівень)

1. Конвертуйте PDF-документ із виносками та колонтитулами, відновіть їх коректне відображення у Word
2. Порівняйте якість конвертації одного й того ж документа трьома різними інструментами (Word, онлайн-сервіс, OCR-програма)
3. Підготуйте покрокову інструкцію "Як правильно виправити таблицю після конвертації PDF у Word"

Завдання В (високий рівень)

1. Виконайте повну реконструкцію складного багатосторінкового PDF-документа (звіт з таблицями, графіками, колонтитулами) у professionally оформлений Word-документ
2. Дослідіть питання конфіденційності при використанні онлайн-конвертерів PDF та підготуйте рекомендації щодо безпечної роботи з чутливими документами
3. Розробіть чек-лист якості для перевірки конвертованого документа перед його використанням у діловодстві

Контрольні питання

1. Що таке формат PDF і чим він відрізняється від DOCX?

2. Які типи PDF-документів існують за походженням?
3. Якими способами можна конвертувати PDF у Word?
4. Чому багатоклонкові PDF-документи складно конвертуються?
5. Які типові проблеми виникають при конвертації таблиць?
6. Що таке OCR і коли він необхідний при роботі з PDF?
7. Як увімкнути відображення непечатних символів у Word і навіщо це потрібно?
8. Які ризики приватності пов'язані з використанням онлайн-конвертерів?
9. Як виправити неправильні розриви рядків після конвертації?
10. Які переваги має Adobe Acrobat Pro перед безкоштовними онлайн-конвертерами?
11. Що робити, якщо після OCR-розпізнавання виникло багато помилок у тексті?
12. Як застосування стилів заголовків допомагає відновити структуру документа?

Форма звіту

Звіт повинен містити:

1. Мета роботи
2. Результати виконання завдань 1-7 (таблиці, скріншоти)
3. Виконане самостійне завдання (на вибір А, Б або В)
4. Відповіді на контрольні питання (мінімум 8)
5. Висновки щодо вибору оптимального способу конвертації PDF для різних типів документів

Критерії оцінювання

Шкала оцінювання (12-бальна система):

- **12 балів** — виконані всі завдання з повною документацією, виконане завдання високого рівня (В), вичерпні відповіді на контрольні питання
- **10-11 балів** — виконані всі основні завдання, виконане завдання середнього рівня (Б), правильні відповіді на питання
- **7-9 балів** — виконані обов'язкові завдання, виконане базове завдання (А), є відповіді на основні питання
- **4-6 балів** — виконана більша частина завдань, часткові відповіді на питання
- **1-3 бали** — виконана менша частина завдань, недостатня документація

- **0 балів** — робота не виконана

Література та ресурси

1. Офіційна документація Microsoft Word: <https://support.microsoft.com/word>
2. Документація Adobe Acrobat: <https://helpx.adobe.com/acrobat>
3. Матеріали ABBYY FineReader: <https://www.abbyy.com>
4. "Цифрове діловодство та документообіг" — навчально-методичні матеріали

Додаток А. Глосарій термінів

- **PDF (Portable Document Format)** — портативний формат документа
- **OCR (Optical Character Recognition)** — оптичне розпізнавання символів
- **Текстовий шар** — прихований редагований текст у PDF-документі
- **Растровий PDF** — PDF, що складається із зображень без тексту
- **Docx** — формат документів Microsoft Word
- **Розрив рядка/абзацу** — символ форматування, що визначає межу рядка чи абзацу

Підсумки практичної роботи

Після виконання цієї практичної роботи ви:

Дізналися:

- Особливості структури PDF-документів різних типів
- Способи конвертації PDF у Word та їх обмеження
- Принципи роботи OCR при розпізнаванні сканованих документів

Навчилися:

- Конвертувати PDF-документи різної складності у редагований формат
- Виправляти типові проблеми форматування після конвертації
- Оцінювати якість та обирати оптимальний інструмент конвертації

Викладач: _____

Дата: _____